

Universitatea din București
Facultatea de Matematică și Informatică

METODE MODERNE DE CALCUL ȘI SIMULARE

Cursurile nr. 1-4 – Anul III – Tehnologia Informației

Asist. dr. Bianca Mogoș

București, Februarie 2014

Cuprins

1	Noțiuni de probabilități și statistică- Partea I	2
1.1	Experiment aleator. Spațiu de selecție.	2
1.2	Evenimente	2
1.3	Axiomele probabilității. Câmp de probabilitate	3
1.4	Probabilități condiționate	5
1.5	Formula lui Bayes	6
2	Noțiuni de probabilități și statistică - Partea a II-a	8
2.1	Variabile aleatoare discrete	8
2.1.1	Variabile aleatoare. Funcție de repartiție	8
2.1.2	Operații cu variabile aleatoare discrete	9
2.1.3	Momente. Definiții	10
2.1.4	Proprietăți ale valorii medii	11
2.2	Variabile aleatoare continue	12
2.2.1	Funcția de repartiție. Densitatea de probabilitate	12
2.2.2	Caracteristici ale variabilelor aleatoare continue	13
2.2.3	Funcții de o variabilă aleatoare	14
2.3	Exemple de repartiții discrete	16
2.3.1	Repartiția Bernoulli	16
2.3.2	Repartiția binomială	16
2.3.3	Repartiția geometrică	17
2.3.4	Repartiția Pascal	18
2.3.5	Repartiția Poisson	19
2.4	Exemple de repartiții continue	19
2.5	Vectori aleatori	19
2.5.1	Funcția de repartiție. Densitatea de repartiție.	19
3	Noțiuni de probabilități și statistică - Partea a III-a	21
3.1	Model probabilist	21
3.2	Noțiunea de selecție. Model statistic.	21
3.3	Statistici. Momente de selecție	23
3.4	Estimarea parametrilor	24
	Bibliografie	26

Capitolul 1

Noțiuni de probabilități și statistică- Partea I

1.1 Experiment aleator. Spațiu de selecție.

Definiția 1.1.1. (*Experiment aleator*)

Un experiment aleator este definit ca fiind o acțiune al cărei rezultat nu poate fi prezis cu certitudine și care se poate modifica în urma repetării experimentului.

Observație 1.1.2. Variabilitatea rezultatelor ieșite în urma unui experiment aleator poate apărea ca urmare a unor erori de măsurare, a alegerii unor obiecte diferite pentru testare, etc.

Exemplul 1.1.3.

- Observarea pe un interval T de timp a funcționării unui calculator.
- Înregistrarea consumului de energie electrică a unui combinat.

Definiția 1.1.4. (*Spațiu de selecție*)

Spațiul de selecție al unui experiment aleator, notat prin Ω , reprezintă mulțimea tuturor rezultatelor posibile.

Exemplul 1.1.5.

- Prin aruncarea banului se pot obține două rezultate. Astfel, spațiul de selecție este $\{0,1\}$.
- Prin rostogolirea unui zar cu șase fețe și numărarea punctelor de pe o față se pot obține șase rezultate posibile. Astfel, spațiul de selecție este $\{1,2,3,4,5,6\}$.

1.2 Evenimente

Definiția 1.2.1. (*Eveniment*)

Un eveniment este orice submulțime de rezultate conținute în spațiul de selecție. Un eveniment este elementar dacă el constă dintr-un singur rezultat și compus dacă constă din mai multe rezultate.

Definiția 1.2.2. (*Evenimentul sigur și evenimentul imposibil*)

Evenimentul sigur este evenimentul care se realizează întotdeauna ca rezultat al experimentului; va fi notat cu Ω (se asociază mulțimii totale de rezultate).

Evenimentul imposibil nu se poate realiza ca rezultat al unui experiment; va fi notat cu \emptyset (corespunde mulțimii vide).

Definiția 1.2.3. (*Reuniunea și intersecția evenimentelor*)

Numim reuniunea evenimentelor A_1, A_2, \dots, A_k , notată prin $\bigcup_{j=1}^k A_j$, evenimentul care se realizează când cel puțin unul dintre evenimentele A_1, A_2, \dots, A_k se realizează.

Numim intersecția evenimentelor A_1, A_2, \dots, A_k , notată prin $\bigcap_{j=1}^k A_j$, evenimentul care se realizează când se realizează toate evenimentele A_1, A_2, \dots, A_k .

1.3 Axiomele probabilității. Câmp de probabilitate

Probabilitatea unui eveniment este o măsură prin care gestionăm/modelăm incertitudinea producerii fenomenelor și a apariției datelor din lumea reală. Aceasta ne permite să apreciem gradul de încredere și să cuantificăm lipsa de siguranță inerentă în procesul care generează datele analizate.

Definiția 1.3.1. (*Definiția clasică a probabilității*)

Dacă într-un experiment cu “ n ” rezultate, “ k ” dintre ele favorizează realizarea evenimentului A , definim probabilitatea $P(A)$ a evenimentului A prin

$$P(A) = \frac{k}{n} \quad (1.3.1)$$

Exercițiul 1.3.2. (*Aruncarea cu zarul*)

1. Calculați probabilitatea ca în urma aruncării unui zar să iasă un număr par.
2. Care este probabilitatea ca în urma aruncării unui zar să iasă un număr impar, strict mai mare ca 3?

Teoria modernă a probabilităților a fost fondată la începutul secolului XX. O contribuție esențială a avut-o matematicianul rus A. Kolmogorov.

Fie Ω mulțimea evenimentelor elementare (rezultatelor posibile) ale unui experiment aleator.

Definiția 1.3.3. (*σ – algebră*)

$\mathcal{B} \subset \mathcal{P}(\Omega)$ este o σ – algebră dacă

1. $\emptyset, \Omega \in \mathcal{B}$
2. Dacă $A \in \mathcal{B}$ atunci $A^C \in \mathcal{B}$
3. Dacă $(A_n)_{n \in \mathbb{N}^*}, A_n \in \mathcal{B}$ atunci $\bigcup_{n=1}^{\infty} A_n \in \mathcal{B}$

Perechea (Ω, \mathcal{B}) se numește câmp de evenimente.

Definiția 1.3.4. (*Probabilitate*)

Se numește probabilitate pe \mathcal{B} o funcție nenegativă $P : \mathcal{B} \rightarrow [0, 1]$ cu proprietățile:

1. $P(\Omega) = 1$
2. Dacă $A, B \in \mathcal{B}$ și $A \cap B = \emptyset$ atunci $P(A \cup B) = P(A) + P(B)$.

Proprietăți 1.3.5.

1. $P(A^C) = 1 - P(A)$, deoarece $A \cup A^C = \Omega, A \cap A^C = \emptyset$.
2. $P(\emptyset) = P(\Omega^C) = 1 - P(\Omega) = 0$.
3. $P(A \cup B) = P(A) + P(B) - P(A \cap B)$, dacă $A \cap B \neq \emptyset$.

Relația 3) se demonstrează astfel:

$$A = A \cap (B \cup B^C) = (A \cap B) \cup (A \cap B^C) \text{ cu } A \cap B \cap B^C = \emptyset.$$

$$B = B \cap (A \cup A^C) = (B \cap A) \cup (B \cap A^C) \text{ cu } B \cap A \cap A^C = \emptyset.$$

$$\text{Dar, } A \cup B = (A \cap B) \cup (A \cap B^C) \cup (B \cap A^C).$$

Aplicăm axioma 2) din definiția probabilității și obținem

$$P(A) = P(A \cap B) + P(A \cap B^C)$$

$$P(B) = P(A \cap B) + P(B \cap A^C)$$

$$P(A \cup B) = P(A \cap B) + P(A \cap B^C) + P(B \cap A^C)$$

Din cele trei relații deduse mai sus rezultă proprietatea 3.

Definiția 1.3.6. (*Câmp de probabilitate*)

Tripletul (Ω, \mathcal{B}, P) se numește câmp de probabilitate.

Exercițiul 1.3.7. (*Problema controlului alimentelor*)

Se știe că într-o cutie sunt 550 de mere. Se verifică aleator 25 dintre ele dacă sunt stricate. Dacă 2% dintre merele din cutie sunt stricate, care este probabilitatea ca printre cele 25 testate să găsim 2 mere stricate?

Exercițiul 1.3.8. (*Problema zilei de naștere*)

Care este probabilitatea ca cel puțin 2 persoane dintr-un grup de n indivizi să aibă aceeași zi de naștere?

1.4 Probabilități condiționate

Definiția 1.4.1. Evenimente independente

Două evenimente A și B din \mathcal{B} sunt independente dacă nu se influențează, adică realizarea evenimentului A nu depinde de realizarea lui B și reciproc.

Definiția 1.4.2. (Probabilitate condiționată)

Se numește probabilitate condiționată a evenimentului A de către evenimentul B și se notează $P(A|B)$ sau $P_B A$ probabilitatea de realizare a evenimentului A calculată în condiția că evenimentul B s-a realizat ($P(B) > 0$) și se definește ca:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Exemplul 1.4.3.

Un tratament s-a aplicat la 700 de pacienți care sufereau de piatră la rinichi. S-a constatat că doar 562 s-au vindecat. De asemenea, se știe că 357 au pietre mici și 315 dintre aceștia s-au vindecat, iar 343 au pietre mari și 247 s-au vindecat. Să se calculeze probabilitatea ca un pacient să se vindece știind că acesta are piatră mică. Dar, dacă are piatră mare?

Soluție:

Fie

$\Omega = \{1, 2, \dots, 700\}$ mulțimea tuturor pacienților,

$S = \{1, 2, \dots, 562\}$ mulțimea pacienților vindecați și

$E = \{563, \dots, 700\}$ mulțimea pacienților nevindecați.

Obținem următoarele probabilități:

$$P(\omega) = \frac{1}{700}, \forall \text{ evenimentul elementar } \omega \in \Omega$$

$$P(S) = \frac{562}{700} \approx 0,8$$

$$P(E) = \frac{138}{700} \approx 0,2$$

Notăm cu

$\Omega_1 =$ pacienții care au pietre mici

$\Omega_2 =$ pacienții care au pietre mari

Rezultă $P(\Omega_1) = \frac{357}{700} = 0,51$ și $P(\Omega_2) = \frac{343}{700} = 0,49$. Astfel

$$P(S|\Omega_1) = \frac{P(S \cap \Omega_1)}{P(\Omega_1)} = \frac{315}{700} \cdot \frac{1}{0,51} = 0,88$$

Analog, se arată că

$$P(S|\Omega_2) = 0,72.$$

Exercițiul 1.4.4.

Presupunem că 1% din populație este bolnavă. Un test de analiză a sângelui dă următoarele rezultate: în 95% dintre cazuri testul iese pozitiv pentru persoanele bolnave și în 2% dintre cazuri iese pozitiv pentru persoanele sănătoase. Care este probabilitatea ca o persoană careia i-a ieșit testul pozitiv să fie bolnavă?

Definiția 1.4.5. (*Evenimente independente în totalitate*)

Spunem că evenimentele A_1, A_2, \dots, A_k sunt independente în totalitate dacă sunt independente două câte două, sunt independente trei câte trei, ..., sunt independente toate " k ".

Formal, avem relațiile:

$$P(A_{i_1} \cap A_{i_2} \cap \dots \cap A_{i_p}) = P(A_{i_1})P(A_{i_2}) \dots P(A_{i_p}),$$

$$\forall i_1, \dots, i_p \in \overline{1, k} \text{ distincte}, p = \overline{1, k}$$

Exemplul 1.4.6. (*Evenimentele nu sunt independente în totalitate*)

Fie spațiul de selecție $\Omega = \{1, 2, 3, 4\}$ și evenimentele.

$$A = \{1, 2\}$$

$$B = \{1, 3\}$$

$$C = \{1, 4\}$$

Cum $A \cap B = \{1\}$ rezultă $P(A \cap B) = \frac{1}{4} = \frac{1}{2} \cdot \frac{1}{2} = P(A)P(B)$. Rezultă că evenimentele A și B sunt independente.

Iar $P(A \cap B \cap C) = \frac{1}{4} \neq P(A)P(B)P(C) = \frac{1}{8}$. Deducem că evenimentele A , B și C nu sunt independente.

1.5 Formula lui Bayes

Fie $(A_i)_{i=\overline{1, k}}$ o partiție a mulțimii Ω , ceea ce înseamnă că

$$A_i \cap A_j = \emptyset, \forall i, j \in \overline{1, k}, i \neq j, P(A_j) > 0, \forall j = \overline{1, k} \text{ și } \bigcup_{j=1}^k A_j = \Omega.$$

Fie $X \in \mathcal{B}$ un eveniment oarecare. Atunci

$$P(X) = P(X \cap \Omega) = P\left(\bigcup_{j=1}^k X \cap A_j\right) = \sum_{j=1}^k P(X \cap A_j) = \sum_{j=1}^k P(A_j) \cdot P(X|A_j)$$

Obținem relația

$$P(X) = \sum_{j=1}^k P(A_j) \cdot P(X|A_j)$$

Atunci probabilitatea condiționată a evenimentului A_j de către evenimentul X se poate calcula cu formula

$$P(A_j|X) = \frac{P(A_j) \cdot P(X|A_j)}{\sum_{j=1}^k P(A_j) \cdot P(X|A_j)}. \quad (1.5.1)$$

Relația obținută în ecuația (1.5.1) se numește formula lui Bayes.

Exemplul 1.5.1. (*Exemplu bazat pe formula lui Bayes*)

Presupunem că trei mașini A , B și C lucrează cu următoarele performanțe: probabilitatea ca o piesă să fie defectă este 0,01; 0,02 și 0,04 pentru mașinile A , B și respectiv C . În aceeași zi mașina A a produs 3900 de piese, mașina B 4200 de piese, iar mașina C 3600 de piese. Se alege la întâmplare o piesă din producția acelei zile și se constată că este defectă. Care este probabilitatea să fi fost produsă de mașina C ?

Soluție: Notăm cu

Ω = mulțimea tuturor pieselor produse într-o zi

A = evenimentul: piesa este produsă de mașina A

B = evenimentul: piesa este produsă de mașina B

C = evenimentul: piesa este produsă de mașina C

Atunci

$$P(A) = \frac{3900}{11700} = 0,33$$

$$P(B) = \frac{4200}{11700} = 0,36$$

$$P(C) = \frac{3600}{11700} = 0,31$$

De asemenea, notăm cu D = evenimentul: piesa este defectă. Avem din enunț probabilitățile condiționate: $P(D|A) = 0,01$; $P(D|B) = 0,02$ și $P(D|C) = 0,04$

Atunci aplicând formula Bayes obținem

$$P(C|D) = \frac{P(C) \cdot P(D|C)}{\sum_{A \in \{A,B,C\}} P(A) \cdot P(D|A)} = \frac{0,31 \cdot 0,04}{0,0229} = 0,54.$$

Capitolul 2

Noțiuni de probabilități și statistică - Partea a II-a

2.1 Variabile aleatoare discrete

2.1.1 Variabile aleatoare. Funcție de repartiție

Fie (Ω, \mathcal{B}) un câmp de evenimente.

Definiția 2.1.1. (*Variabilă aleatoare*)

Numim variabilă aleatoare o funcție $X : \Omega \rightarrow \mathbb{R}$ cu proprietatea că pentru fiecare $x \in \mathbb{R}$ evenimentul $X^{-1}(x) = \{\omega \in \Omega | X(\omega) = x\}$ aparține mulțimii \mathcal{B} .

Fie evenimentul $A = \{\omega \in \Omega | X(\omega) \leq x\} \in \mathcal{B}$.

Definiția 2.1.2. (*Funcție de repartiție*)

Funcția $F_X : \mathbb{R} \rightarrow [0, 1]$ definită prin

$$F_X(x) = P(\{\omega \in \Omega | X(\omega) \leq x\}) \quad (2.1.1)$$

se numește funcția de repartiție a variabilei aleatoare X .

Proprietăți 2.1.3.

1. $F_X(x) \in [0, 1]$, $\lim_{x \rightarrow \infty} F_X(x) = 1$, $\lim_{x \rightarrow -\infty} F_X(x) = 0$.
2. $F_X(x + h) \geq F_X(x)$, pentru $h > 0$, deoarece
 $F_X(x + h) = F_X(x) + P(\{\omega \in \Omega | x < X(\omega) \leq x + h\})$.
3. $P(\{\omega \in \Omega | a < X(\omega) \leq b\}) = F_X(b) - F_X(a)$.

Definiția 2.1.4. (*Variabilă aleatoare discretă*)

Dacă valorile luate de variabila aleatoare X sunt în număr finit sau numărabil, spunem că X este o variabilă aleatoare discretă.

Ea este perfect determinată dacă se cunosc valorile luate de variabila aleatoare,

precum și probabilitățile cu care apar aceste valori.
Putem scrie

$$X : \begin{pmatrix} x_1 & x_2 & \dots & x_n & \dots \\ p_1 & p_2 & \dots & p_n & \dots \end{pmatrix} \quad (2.1.2)$$

unde $p_n = P(\{\omega \in \Omega | X(\omega) = x_n, \})$, $n = 1, 2, \dots$

Definiția 2.1.5. (*Repartiția unei variabile aleatoare discrete*)

Tabloul din ecuația (2.1.2) se numește repartiția variabilei aleatoare discrete X .

Observație 2.1.6.

$$\begin{aligned} 1. \quad & p_1 + p_2 + \dots + p_n + \dots = P(\{\omega \in \Omega | X(\omega) = x_1, \}) + P(\{\omega \in \Omega | X(\omega) = x_2, \}) + \\ & + \dots + P(\{\omega \in \Omega | X(\omega) = x_n, \}) + \dots = P(\Omega) = 1 \end{aligned}$$

deoarece evenimentele $A_i = \{\omega \in \Omega | X(\omega) = x_i, \}$ și $\{\omega \in \Omega | X(\omega) = x_j, \}$ cu $i \neq j$ sunt disjuncte (adică, $A_i \cap A_j = \emptyset$; altfel avem evenimentul $e \in A_i \cap A_j$, de unde rezultă $X(e) = x_i = x_j$, ceea ce este imposibil pentru $i \neq j$) și $\bigcup_i A_i = \Omega$

2. O variabilă aleatoare discretă realizează o partiție a câmpului de evenimente.

2.1.2 Operații cu variabile aleatoare discrete

Definiția 2.1.7. (*Operații cu variabile aleatoare discrete*) Dacă X și Y sunt definite pe același câmp de probabilitate (Ω, \mathcal{B}, P) atunci:

$$\begin{aligned} (X + Y)(\omega) &= X(\omega) + Y(\omega) \\ (aX)(\omega) &= aX(\omega), \text{ pentru } a \in \mathbb{R} \\ (XY)(\omega) &= X(\omega)Y(\omega) \\ \frac{X}{Y}(\omega) &= \frac{X(\omega)}{Y(\omega)}, \text{ dacă } Y(\omega) \neq 0 \text{ pentru orice } \omega \in \Omega \end{aligned}$$

Dacă

$$X : \begin{pmatrix} x_1 & x_2 & \dots & x_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}, Y : \begin{pmatrix} y_1 & y_2 & \dots & y_m \\ q_1 & q_2 & \dots & q_m \end{pmatrix}$$

atunci

$$X + Y : \begin{pmatrix} x_1 + y_1 & x_1 + y_2 & \dots & x_i + y_j & \dots & x_n + y_m \\ p_{11} & p_{12} & \dots & p_{ij} & \dots & p_{nm} \end{pmatrix}$$

unde $p_{ij} = P(\{\omega \in \Omega | X(\omega) = x_i\} \cap \{\omega \in \Omega | Y(\omega) = y_j\})$.

În cazul în care evenimentele

$$\{\omega \in \Omega | X(\omega) = x_i\} \text{ și } \{\omega \in \Omega | Y(\omega) = y_j\}$$

sunt independente pentru orice $1 \leq i \leq n, 1 \leq j \leq m$ spunem că v.a. X și Y sunt independente. În acest caz, avem $p_{ij} = p_i \cdot q_j$.

Deducem analog relațiile:

$$aX : \begin{pmatrix} ax_1 & ax_2 \dots & ax_n \\ p_1 & p_2 & \dots & p_n \end{pmatrix}$$

$$X \cdot Y : \begin{pmatrix} x_1y_1 & x_1y_2 & \dots & x_1y_j & \dots & x_1y_m \\ p_{11} & p_{12} & \dots & p_{1j} & \dots & p_{1m} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_iy_1 & x_iy_2 & \dots & x_iy_j & \dots & x_iy_m \\ p_{i1} & p_{i2} & \dots & p_{ij} & \dots & p_{im} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_ny_1 & x_ny_2 & \dots & x_ny_j & \dots & x_ny_m \\ p_{n1} & p_{n2} & \dots & p_{nj} & \dots & p_{nm} \end{pmatrix}$$

și

$$X \cdot Y : \begin{pmatrix} x_1/y_1 & x_1/y_2 & \dots & x_1/y_j & \dots & x_1/y_m \\ p_{11} & p_{12} & \dots & p_{1j} & \dots & p_{1m} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_i/y_1 & x_i/y_2 & \dots & x_i/y_j & \dots & x_i/y_m \\ p_{i1} & p_{i2} & \dots & p_{ij} & \dots & p_{im} \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_n/y_1 & x_n/y_2 & \dots & x_n/y_j & \dots & x_n/y_m \\ p_{n1} & p_{n2} & \dots & p_{nj} & \dots & p_{nm} \end{pmatrix}$$

$y_j \neq 0$ pentru orice $j = 1, 2, \dots, m$.

2.1.3 Momente. Definiții

Fie (Ω, \mathcal{B}, P) spațiul de probabilitate pe care este definită variabila aleatoare discretă X .

Definiția 2.1.8. (*Valoare medie a unei variabile aleatoare*)

Dacă X este o variabilă aleatoare, $X : \Omega \rightarrow \mathbb{R}$ atunci numim valoare medie a variabilei X ,

$$E[X] = \sum_{i=1}^{\infty} x_i p_i \quad (2.1.3)$$

pentru cazul în care X ia un număr numărabil de valori și seria este convergentă. Dacă X ia un număr finit de valori, valoarea medie se definește printr-o sumă finită.

Definiția 2.1.9. (*Momentul de ordinul r*)

Momentul de ordinul r al v.a. X este $E_r[X] = E[X^r]$. Se mai folosește notația $\mu_r(X) = E[X^r]$.

Definiția 2.1.10. (*Momentul centrat de ordin r*)

Momentul centrat de ordin r al v.a. X este numărul

$$\mu_r(X) = E[(X - E[X])^r] \quad (2.1.4)$$

Pentru $r = 2$

$$\mu_2(X) = E[(X - E[X])^2] \text{ se numește dispersia variabilei } X. \quad (2.1.5)$$

O notăm cu $D(X)$ și dă o măsură a împrăstierii valorilor variabilei X în jurul valorii ei medii.

Definiția 2.1.11. (*Coeficientul de variație*)

Cantitatea $\sqrt{D(X)}/E[X]$ se numește coeficientul de variație pentru variabila X .

Definiția 2.1.12. (*Coeficientul de asimetrie*)

Cantitatea $E[(X - E[X])^3]/D^{3/2}(X)$ se numește coeficientul de asimetrie pentru variabila X .

Definiția 2.1.13. (*Coeficientul de aplatizare sau de exces*)

Cantitatea $E[(X - E[X])^4]/D^2(X)$ se numește coeficientul de aplatizare sau de exces pentru variabila X .

2.1.4 Proprietăți ale valorii medii

Proprietăți 2.1.14.

$$E[aX + b] = aE[X] + b, a, b \in \mathbb{R}$$

Proprietăți 2.1.15.

$$E[X + Y] = E[X] + E[Y]$$

Demonstrație

$$\begin{aligned} E[X + Y] &= \sum_{i=1}^n \sum_{j=1}^m (x_i + y_j) p_{ij} = \sum_{i=1}^n x_i \sum_{j=1}^m p_{ij} + \sum_{j=1}^m y_j \sum_{i=1}^n p_{ij} \\ &= \sum_{i=1}^n x_i P(X = x_i) + \sum_{j=1}^m y_j P(Y = y_j), \end{aligned}$$

deoarece

$$\sum_{j=1}^m p_{ij} = P((X = x_i) \cap \Omega) = P(X = x_i)$$

și

$$\sum_{i=1}^n p_{ij} = P(\Omega \cap (Y = y_j)) = P(Y = y_j).$$

Proprietăți 2.1.16. Dacă X și Y sunt v.a. independente, atunci

$$E[X \cdot Y] = E[X] \cdot E[Y]$$

Demonstrație

Avem $E[X \cdot Y] = \sum_{i=1}^n \sum_{j=1}^m x_i y_j p_{ij}$. Cum X și Y sunt independente

$$p_{ij} = P(X = x_i) \cdot P(Y = y_j).$$

Astfel,

$$E[X \cdot Y] = \sum_{i=1}^n P(X = x_i) \cdot \sum_{j=1}^m P(Y = y_j).$$

2.2 Variabile aleatoare continue

2.2.1 Funcția de repartiție. Densitatea de probabilitate

Definiția 2.2.1. (*Variabilă aleatoare continuă*)

Spunem că $X : \Omega \rightarrow \mathbb{R}$ este v.a. continuă dacă

$$P(\{\omega \in \Omega | X(\omega) = x\}) = 0, \quad (2.2.1)$$

pentru orice $x \in \mathbb{R}$.

Observație 2.2.2.

Deși probabilitatea evenimentului din definiție este zero nu înseamnă că evenimentul nu se poate realiza.

Proprietăți 2.2.3.

Dacă X este o variabilă aleatoare continuă atunci funcția sa de repartiție este continuă.

Demonstrație

Trebuie să demonstrăm că

$$\lim_{\substack{x \rightarrow x_0 \\ x < x_0}} F_X(x) = \lim_{\substack{x \rightarrow x_0 \\ x > x_0}} F_X(x) = F_X(x_0).$$

Fie $x > x_0$. Avem relația

$$F_X(x) - F_X(x_0) = P(\{\omega \in \Omega | x < X(\omega) \leq x_0\}).$$

Dar,

$$\lim_{\substack{x \rightarrow x_0 \\ x > x_0}} P(\{\omega \in \Omega | x < X(\omega) \leq x_0\}) = 0$$

Atunci

$$\lim_{\substack{x \rightarrow x_0 \\ x > x_0}} F_X(x) = F_X(x_0).$$

Analog, se arată că

$$\lim_{\substack{x \rightarrow x_0 \\ x < x_0}} F_X(x) = F_X(x_0).$$

Definiția 2.2.4. (*Densitate de probabilitate*)

Dacă există

$$\lim_{h \rightarrow 0} \frac{F_X(x+h) - F_X(x)}{h} = F'_X(x) \quad (2.2.2)$$

atunci F'_X se numește densitatea de probabilitate a variabilei X și

$$F'_X(x) = f_X(x), x \in \mathbb{R} \quad (2.2.3)$$

Proprietăți 2.2.5. (*Proprietăți ale funcției de repartiție*)

1. Deoarece $F_X(x) = \int_{-\infty}^x f_X(t)dt$ rezultă $\int_{-\infty}^{\infty} f_X(t)dt = 1$
2. Deoarece F_X este crescătoare rezultă că $f_X(x) \geq 0, x \in \mathbb{R}$.

2.2.2 Caracteristici ale variabilelor aleatoare continue

Definiția 2.2.6. (*Valoare medie a unei variabile aleatoare continue*)

Valoarea medie a v.a. continue X este

$$E[X] = \int_{-\infty}^{\infty} x dF_X(x) = \int_{-\infty}^{\infty} x f_X(x) dx \quad (2.2.4)$$

Definiția 2.2.7. (*Momentul de ordin r al unei variabile aleatoare continue*)

Momentul de ordinul r al variabilei aleatoare continue X este

$$\mu_r(X) = E[X^r] = \int_{\mathbb{R}} x^r f_X(x) dx. \quad (2.2.5)$$

Definiția 2.2.8. (*Momentul centrat de ordin r al unei variabile aleatoare continue*)

Momentul centrat de ordinul r al variabilei aleatoare continue X este

$$\mu_r(X) = E[(X - E[X])^r] = \int_{\mathbb{R}} (x - E[X])^r f_X(x) dx. \quad (2.2.6)$$

Pentru $r = 2$ obținem dispersia variabilei aleatoare X :

$$D(X) = \mu_2(X) = E[(x - E[X])^2] = \int_{\mathbb{R}} (x - E[X])^2 f_X(x) dx. \quad (2.2.7)$$

$\sqrt{D(X)}$ se numește abaterea medie pătratică sau deviația standard.

Proprietățile mediei și dispersiei sunt aceleași ca și pentru variabile aleatoare discrete.

Valoarea medie a unei v.a. este cel mai folosit indicator pentru locație sau poziție. Există de asemenea și modulul și mediana.

Definiția 2.2.9. (*Modulul unei variabile aleatoare*)

Modulul v.a. X , notat prin M_0 , este acea valoare a v.a. X pentru care densitatea de probabilitate $f_X(x)$ are valoare maximă.

Definiția 2.2.10. (*Mediana unei variabile aleatoare*)

Mediana v.a. X , notată prin Me , este acea valoare pentru care

$$\int_{-\infty}^{Me} f_X(x) dx = \int_{Me}^{\infty} f_X(x) dx = \frac{1}{2}. \quad (2.2.8)$$

Definiția 2.2.11. (*Cuantila de ordinul α a unei variabile aleatoare*)

Cuantila de ordinul α a variabile aleatoare X este acea valoare q_α care verifică relația

$$\int_{-\infty}^{q_\alpha} f_X(x) dx = \alpha. \quad (2.2.9)$$

Exercițiul 2.2.12. (*Test*) Timpul de așteptare la un ghișeu este o variabilă aleatoare T care urmează o repartiție $Exp(\lambda)$ cu timpul mediu de așteptare de 15 minute. Să se afle probabilitatea ca un cetățean să aștepte mai mult de 20 de minute.

2.2.3 Funcții de o variabilă aleatoare

Fie X o v.a. $X : \Omega \rightarrow \mathbb{R}$ care ia valori în $D \subset \mathbb{R}$ și $\phi : D \rightarrow \mathbb{R}$, ϕ continuă. Atunci v.a. $Y = \phi(X) : \Omega \rightarrow \phi(D) \subset \mathbb{R}$ are repartiția dată de

$$P(\{\omega \in \Omega | Y(\omega) \in A\}) = P(\{\omega \in \Omega | X(\omega) \in \phi^{-1}(A)\}) \quad (2.2.10)$$

pentru orice $A \subset \phi(D)$ și $\phi^{-1}(A) = \{z | \phi(z) \in A\}$.

Proprietăți 2.2.13.

Dacă $X \sim N(m, \sigma^2)$ atunci $Y = e^X$ are densitatea de repartiție:

$$f_Y(y) = \frac{1}{y\sigma\sqrt{2\pi}} e^{-\frac{(\ln y - m)^2}{2\sigma^2}}, y > 0 \quad (2.2.11)$$

Demonstrație

$$\begin{aligned} F_Y(y) &= P(\{\omega \in \Omega | Y(\omega) \leq y\}) = P(e^X \leq y) = P(X \leq \ln y) = F_X(\ln y) = \\ &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\ln y} e^{-\frac{(t-m)^2}{2\sigma^2}} dt. \end{aligned}$$

Definiția 2.2.14. (*Variabilă aleatoare lognormală*)

Variabila aleatoare Y având densitatea de probabilitate (2.2.11) se numește lognormală.

Proprietăți 2.2.15.

Dacă $X \sim U(0, 1)$ atunci variabila aleatoare

$$Y = \left(-\frac{1}{a} \ln(1 - X) \right)^{1/b}$$

cu $a, b > 0$ are densitatea de probabilitate

$$f(y) = aby^{b-1}e^{-ay^b}, \quad 0 < y < \infty.$$

Definiția 2.2.16. (*Variabilă aleatoare Weibull*)

O variabilă aleatoare cu densitatea de probabilitate (2.2.15) se numește Weibull cu parametrii a și b și este notată $W(a, b)$.

Proprietăți 2.2.17.

Fie X o variabilă aleatoare cu funcția de repartiție inversabilă $F(X)$ de tip continuu care este strict crescătoare. Atunci variabila aleatoare $Y = F(X)$ este repartizată uniform pe $(0, 1)$.

Demonstrație

Funcția de repartiție a variabilei Y este

$$P(Y \leq y) = P(F(X) \leq y) = P(X \leq F^{-1}(y), 0 < y < 1) = F(F^{-1}(y)) = y,$$

$y \in (0, 1)$, ceea ce arată că $Y \sim U(0, 1)$.

Un rezultat pentru reciproca propoziției (2.2.17) este dat în următoarea propoziție.

Proprietăți 2.2.18.

Fie $Y \sim U(0, 1)$ și $F(x)$ o funcție de repartiție inversabilă, de tip continuu cu $F(a) = 0$ și $F(b) = 1$ și F strict crescătoare pe (a, b) . Atunci v.a.

$$X = F^{-1}(Y) \quad (2.2.12)$$

este o v.a. continuă cu funcția de repartiție F .

Demonstrație

Funcția de repartiție a v.a. X este

$$P(X \leq x) = P(F^{-1}(Y) \leq x) = P(Y \leq F(x))$$

deoarece F este strict crescătoare.

Cum $Y \sim U(0, 1)$ rezultă $F_Y(y) = y$ pentru $y \in (0, 1)$. Obținem astfel

$$P(X \leq x) = F(x).$$

2.3 Exemple de repartiții discrete

2.3.1 Repartiția Bernoulli

Fie un eveniment aleator observabil A care are probabilitatea constantă $p = P(A) > 0$. Într-un experiment se poate produce A cu probabilitatea p sau evenimentul contrar A^C cu probabilitatea $q = 1 - p$. Un astfel de experiment se numește *probă Bernoulli*. Când se produce A spunem că s-a realizat un “succes”, iar când A nu se produce spunem că avem un “eșec”.

Observație 2.3.1.

Dacă $p = \frac{1}{2}$ atunci suntem în cazul particular al aruncării la întâmplare cu banul (tragerea la sorți).

Asociem unei probe Bernoulli variabila aleatoare Z astfel încât $Z = 1$ dacă se produce A și $Z = 0$ dacă se produce A^C . Variabila Z are repartiția

$$Z : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}, E[Z] = p, V(Z) = pq = p(1 - p). \quad (2.3.1)$$

Funcția de repartiție a lui Z este

$$F(x) = P(Z \leq x) = \begin{cases} 0, & \text{dacă } x < 0 \\ q, & \text{dacă } 0 \leq x < 1 \\ 1, & \text{dacă } x \geq 1 \end{cases}. \quad (2.3.2)$$

2.3.2 Repartiția binomială

Spunem că variabila discretă $X \in \mathbb{N}$ este o variabilă binomială $Binom(n, p)$, $n \in \mathbb{N}^+$, $0 < p < 1$ dacă X = numărul de succese în n probe Bernoulli independente,

adică

$$X = \sum_{i=1}^n Z_i \quad (2.3.3)$$

unde Z_i sunt variabile identice și independente repartizate Bernoulli.

Repartiția variabilei binomiale X este

$$X : \begin{pmatrix} 0 & 1 & 2 & \dots & x & \dots & n \\ q^n & npq^{n-1} & C_n^2 p^2 q^{n-2} & \dots & C_n^x p^x q^{n-x} & \dots & p^n \end{pmatrix}, q = 1 - p. \quad (2.3.4)$$

Media și dispersia variabilei X sunt date de formulele

$$\begin{aligned} E[X] &= E\left[\sum_{i=1}^n Z_i\right] = \sum_{i=1}^n E[Z_i] = np \\ V(X) &= V\left(\sum_{i=1}^n Z_i\right) = \sum_{i=1}^n V[Z_i] = npq. \end{aligned} \quad (2.3.5)$$

Observație 2.3.2.

Variabila $\text{Binom}(n, p)$ are și o interpretare în termeni de experiment cu urnă. Presupunem că într-o urnă avem A bile albe și B bile negre, $A+B = N$. Presupunem că se realizează extrageri succesive din urnă și după fiecare extragere se introduce bila extrasă la loc în urnă (experimentul cu bila întoarsă). Fie $p = A/N$ probabilitatea de a extrage o bilă albă într-o extracție. De aici rezultă că $X =$ numărul de bile albe în n extrageri succesive cu întoarcere, este o variabilă binomială $\text{Binom}(n, p)$.

Câteva exemple în care rezultatele unui experiment pot fi modelate folosind o variabilă aleatoare binomială.

1. Un medicament are probabilitatea de 0.90 de a vindeca o boală. Acesta este administrat la 100 de pacienți, iar rezultatul pentru fiecare pacient este fie vindecat sau nevindecat. Dacă X este numărul de pacienți vindecați, atunci X este o variabilă aleatoare binomială cu parametrii $(100, 0.9)$.
2. Institutul Național al sănătății mentale estimează că 20% dintre adulții americani suferă de o afecțiune psihiatrică. Sunt selectați aleator 50 de adulți. Dacă notăm cu X numărul de persoane cu afecțiuni, atunci X ia valori în concordanță cu repartiția binomială cu parametrii $(50, 0.2)$.

Exercițiul 2.3.3.

Pentru exemplul 2, calculați probabilitatea ca cel mult 3 persoane selectate să sufere de o boală psihică.

2.3.3 Repartiția geometrică

Variabila X are repartiția $\text{Geom}(p)$, $0 < p < 1$ dacă $X =$ numărul de eșecuri până la apariția unui succes într-un șir oarecare de probe Bernoulli independente.

Repartiția variabilei $Geom(p)$, X , este

$$X : \begin{pmatrix} 0 & 1 & 2 & \dots & x & \dots \\ p & pq & pq^2 & \dots & P(X=x) = pq^x & \dots \end{pmatrix}, q = 1 - p. \quad (2.3.6)$$

Funcția de repartiție a variabilei X se poate calcula cu formula

$$F(x) = P(X \leq x) = \sum_{i=0}^x pq^i = 1 - q^{x+1}, x = 0, 1, 2, \dots \quad (2.3.7)$$

Media și dispersia variabilei X sunt date de formulele

$$\begin{aligned} E[X] &= \frac{q}{p} \\ V(X) &= \frac{q}{p^2}. \end{aligned} \quad (2.3.8)$$

Observație 2.3.4.

Interpretarea cu urnă din cazul repartiției $Binom(n, p)$ se poate adapta și la cazul repartiției $Geom(p)$. Astfel, numărul X de bile negre extrase cu întoarcere până când se obține o bilă albă, este o variabilă $Geom(p)$.

2.3.4 Repartiția Pascal

Variabila X are repartiția $Pascal(k, p)$, $k \in \mathbb{N}^+$, $0 < p < 1$ dacă X = numărul de eșecuri până la apariția a k succese într-un șir oarecare de probe Bernoulli independente.

Repartiția variabilei $Pascal(k, p)$, X , este

$$X : \begin{pmatrix} 0 & 1 & 2 & \dots & x & \dots \\ p^k & kp^k q & C_{k+1}^{k-1} p^k q^2 & \dots & P(X=x) = C_{x+k-1}^{k-1} p^k q^x & \dots \end{pmatrix}, \quad (2.3.9)$$

$$q = 1 - p, x = 0, 1, 2, \dots$$

Media și dispersia variabilei X sunt date de formulele

$$\begin{aligned} E[X] &= \frac{kq}{p} \\ V(X) &= \frac{kq}{p^2}. \end{aligned} \quad (2.3.10)$$

Observație 2.3.5.

Interpretarea cu urnă din cazul repartiției $Geom(p)$ se poate extinde și la cazul repartiției $Pascal(k, p)$. Astfel, numărul X de bile negre extrase cu întoarcere până când se obțin k bile albe, este o variabilă $Pascal(k, p)$.

2.3.5 Repartiția Poisson

O variabilă aleatoare X este o variabilă aleatoare Poisson cu parametrul $\lambda, \lambda > 0$ dacă are funcția de probabilitate dată prin

$$P(X = x) = \frac{\lambda^x}{x!} e^{-\lambda}, \lambda > 0 \quad (2.3.11)$$

Media și dispersia variabilei aleatoare Poisson X sunt

$$\begin{aligned} E[X] &= \lambda \\ \text{și} \\ V(X) &= \lambda. \end{aligned} \quad (2.3.12)$$

Repartiția Poisson poate fi utilizată în numeroase aplicații. Câteva situații în care o variabilă aleatoare discretă poate avea o distribuție Poisson sunt:

- numărul erorilor de tipografie dintr-o pagină;
- numărul concediilor dintr-o firmă în decursul unei luni
- numărul defectelor de-a lungul unui fir.

Observație 2.3.6.

Repartiția Poisson este adesea utilizată pentru a aproxima repartiția binomială. Pentru valori mari ale lui n și mici ale lui p (deci valori moderate pentru np), numărul de succese apărute în n probe poate fi aproximat de variabila aleatoare Poisson cu parametrul $\lambda = np$.

Exemplul 2.3.7.

Presupunem că numărul erorilor dintr-o pagină a unui manuscris urmează o distribuție Poisson cu parametrul $\lambda = 0.25$. Calculăm probabilitatea ca o pagină să aibă cel puțin 2 erori precum urmează:

$$P(X \geq 2) = 1 - (P(X = 0) + P(X = 1)) = 1 - e^{-0.25} - 0.25 \cdot e^{-0.25} \approx 0.0265$$

2.4 Exemple de repartiții continue

Vezi Capitolul 2 din [Martinez, Martinez (2002)].

2.5 Vectori aleatori

2.5.1 Funcția de repartiție. Densitatea de repartiție.

Definiția 2.5.1. (*Vector aleator*)

Un vector aleator multidimensional $X = (X_1, X_2, \dots, X_k)$ este definit de funcția $X : \Omega \rightarrow \mathbb{R}^k$ care asociază evenimentului $\omega \in \Omega$ vectorul

$$X(\omega) = (X_1(\omega), X_2(\omega), \dots, X_k(\omega)). \quad (2.5.1)$$

Astfel, $X : \Omega \rightarrow \mathbb{R}$ este vector aleator bidimensional dacă pentru orice pereche $(A_1, A_2) \in \mathbb{R}^2$, $(A_1, A_2) : A_1 \in (-\infty, x_1], A_2 \in (-\infty, x_2]$, evenimentul

$$\{\omega \in \Omega | X_1(\omega) \in A_1 \text{ și } X_2(\omega) \in A_2\}$$

aparține mulțimii \mathcal{B} .

Definiția 2.5.2. (*Funcție de repartiție a unui vector aleator*)

Fie $X = (X_1, X_2, \dots, X_k) : \Omega \rightarrow \mathbb{R}^k$ un vector aleator. Funcția

$$F_X : \mathbb{R}^k \rightarrow [0, 1]$$

definită prin

$$F_X(x) = F_X(x_1, x_2, \dots, x_k) = P(\{\omega \in \Omega | X_1(\omega) \leq x_1, \dots, X_k(\omega) \leq x_k\})$$

se numește funcția de repartiție a vectorului X .

Proprietăți 2.5.3.

1. $\lim_{x_j \rightarrow -\infty} F_X(x_1, x_2, \dots, x_k) = 0, \forall 1 \leq j \leq k$
2. $\lim_{(x_1, \dots, x_k) \rightarrow (\infty, \dots, \infty)} F_X(x_1, x_2, \dots, x_k) = 1$
3. $\lim_{x_j \rightarrow \infty} F_X(x_1, \dots, x_j, \dots, x_k) = F_{(x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k)}(x_1, \dots, x_{j-1}, x_{j+1}, \dots, x_k)$

Definiția 2.5.4. (*Densitate de probabilitate a unui vector aleator*)

Dacă există $f_X : \mathbb{R}^k \rightarrow \mathbb{R}$ astfel încât

$$F_X(x_1, x_2, \dots, x_k) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_k} f_X(u_1, u_2, \dots, u_k) du_1 du_2 \dots du_k \quad (2.5.2)$$

atunci f se numește densitatea de repartiție a vectorului X .

Proprietăți 2.5.5.

1. $\int_{\mathbb{R}^k} f_X(x_1, \dots, x_k) dx_1 \dots dx_k = 1$
2. $f_X(x_1, \dots, x_k) = \frac{\partial^k F(x_1, \dots, x_k)}{\partial x_1 \dots \partial x_k}$
3. $P(X_1 \in A_1, X_2 \in A_2, \dots, X_k \in A_k) = \int_{A_1 \times \dots \times A_k} f_X(x_1, \dots, x_k) dx_1 \dots dx_k$

Capitolul 3

Noțiuni de probabilități și statistică - Partea a III-a

3.1 Model probabilist

Fie X o v.a. cu densitatea $f(x, \theta), x \in \mathbb{R}, \theta \in \mathbb{R}$.

Definiția 3.1.1. (*Model probabilist unidimensional*)

Mulțimea densităților de probabilitate $f(x, \theta), \theta \in \Theta \subset \mathbb{R}$, ce conține parametrul necunoscut θ se numește model probabilist.

$$\{f(x, \theta) | x \in \mathbb{R}, \theta \in \Theta\}. \quad (3.1.1)$$

Fie $X = (X_1, X_2, \dots, X_n)$ un vector aleator cu densitatea

$$f(x_1, x_2, \dots, x_n; \theta), (x_1, x_2, \dots, x_n) \in \mathbb{R}^n, \theta \in \mathbb{R}^k.$$

Definiția 3.1.2. (*Model probabilist multidimensional*)

Mulțimea densităților de probabilitate $f(x_1, x_2, \dots, x_n; \theta)$ cu parametrul $\theta \in \Theta \subset \mathbb{R}^k$ se numește model probabilist.

$$\{f(x_1, x_2, \dots, x_n; \theta) | \theta \in \Theta\}. \quad (3.1.2)$$

3.2 Noțiunea de selecție. Model statistic.

Experimentul aleator se realizează pentru colectarea de date necesară pentru a obține informații privind un anumit fenomen de interes. Pe baza datelor se emit concluzii care, în general, ies din sfera experimentului particular. Cercetătorii generalizează concluziile experimentului pentru clasa tuturor experimentelor similare. Acesta este cadrul statisticii inferențiale. Problema acestui demers este că nu putem garanta corectitudinea concluziilor obținute. Totuși, folosind tehnici statistice, putem măsura și administra gradul de incertitudine al rezultatelor.

Statistica inferențială este o colecție de metode care permit cercetătorilor să observe o submulțime a obiectelor de interes și folosind informația obținută pe baza acestor observații să facă afirmații sau inferențe privind întreaga populație. Câteva dintre aceste metode sunt estimarea parametrilor unei populații, verificarea ipotezelor statistice și estimarea densității de probabilitate.

Populația țintă este definită ca fiind întreaga colecție de obiecte sau indivizi despre care vrem să obținem anumite informații. Populația țintă trebuie bine definită indicând ce constituie membrii acesteia (de exemplu, populația unei zone geografice, o anumită firmă care construiește componente hardware, etc.) și caracteristicile populației (starea de sănătate, numărul de defectiuni, etc.).

În majoritatea cazurilor este imposibil sau nerealist să observăm întreaga populație. Astfel, cercetătorii măsoară numai o parte a populației țintă, denumită eșantion. Pentru a face inferențe privind întreaga populație, folosind informația obținută pe baza populației eșantion, este foarte important ca mulțimea eșantion să fie reprezentativă relativ la întreaga populație.

Definiția 3.2.1. (*Mulțime de selecție*)

O selecție este o mulțime de variabile aleatoare X_1, X_2, \dots, X_n având aceeași densitate de probabilitate $f(x, \theta)$.

Datele observate (datele eșantionului) nu sunt considerate ca o mulțime de numere; ele reprezintă rezultatul unui experiment. Deoarece selecția este o mulțime de variabile aleatoare asociate unui model probabilist, selecția trebuie să aibă o repartiție, pe care o vom numi repartiție de selecție.

Definiția 3.2.2. (*Repartiția unei selecții*)

Repartiția selecției X_1, X_2, \dots, X_n este definită ca fiind repartiția vectorului $X = (X_1, X_2, \dots, X_n)$, notată prin $f(x_1, x_2, \dots, x_n; \theta)$.

Cea mai folosită formă de selecție este selecția aleatoare și este bazată pe ideea experimentului aleator.

Definiția 3.2.3. (*Selecție aleatoare*)

Spunem că X_1, X_2, \dots, X_n este o selecție aleatoare asupra v.a. X care are densitatea de probabilitate $f(x; \theta)$ dacă X_1, X_2, \dots, X_n sunt v.a. independente și identic repartizate ca X .

X_1, X_2, \dots, X_n se numesc variabile de selecție.

În cazul selecției aleatoare, densitatea de probabilitate comună a variabilelor de selecție este

$$f(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

O selecție aleatoare poate fi construită prin repetarea unui experiment aleator de n ori.

Realizarea selecției aleatoare se notează prin (x_1, x_2, \dots, x_n) și mulțimea tuturor realizărilor definesc spațiul observațiilor $S \equiv \mathbb{R}^n$.

Definiția 3.2.4. (*Model statistic*)

Modelul probabilist

$$\{f(x; \theta), \theta \in \Theta\}$$

împreună cu selecția $X = (X_1, X_2, \dots, X_n)$ definesc modelul statistic.

3.3 Statistici. Momente de selecție

Definiția 3.3.1. (*Statistică*)

Statistica este o funcție $t_n : S \rightarrow \Theta \subset \mathbb{R}^k$ care nu depinde de nici un parametru.

Cele mai utilizate statistici sunt momentele de selecție.

Definiția 3.3.2. (*Moment de selecție de ordinul r*)

Momentul de selecție de ordinul r , notat m'_r , este definit prin

$$m'_r = \frac{1}{n} \sum_{j=1}^n X_j^r. \quad (3.3.1)$$

Momentul de selecție de ordin unu, m'_1 , se notează prin \bar{X}_n și se numește media de selecție,

$$m'_1 = \bar{X}_n = \frac{1}{n} \sum_{j=1}^n X_j. \quad (3.3.2)$$

Proprietăți 3.3.3.

Avem

$$E[m'_r] = E[X^r] = \mu'_r$$

și în particular,

$$E[\bar{X}_n] = \mu, D(\bar{X}_n) = \frac{\sigma^2}{n}.$$

Definiția 3.3.4. (*Convergență în probabilitate*)

Șirul de v.a. $(X_n)_n$ converge în probabilitate la v.a. X dacă

$$\lim_{n \rightarrow \infty} P(\{\omega \in \Omega, |X_n(\omega) - X(\omega)| < \epsilon\}) = 1. \quad (3.3.3)$$

Proprietăți 3.3.5.

Avem relația

$$\overline{X}_n \xrightarrow[n \rightarrow \infty]{P} E[X] = \mu$$

Demonstrație.

Rezultă din aplicarea inegalității lui Cebîșev descrisă în cele ce urmează. Pentru fiecare v.a. X de pătrat integrabilă și fiecare $a > 0$, obținem

$$P(|X - E[X]| \geq a) \leq \frac{D(X)}{a^2}. \quad (3.3.4)$$

Definiția 3.3.6. (*Moment centrat de selecție de ordin r*)

Momentul centrat de selecție de ordin r se notează prin m_r și este definit de

$$m_r = \frac{1}{n} \sum_{j=1}^n (X_j - \overline{X}_n)^r. \quad (3.3.5)$$

Cel mai utilizat moment centrat de selecție este momentul de ordinul doi, numit dispersia de selecție

$$m_2 = \frac{1}{n} \sum_{j=1}^n (X_j - \overline{X}_n)^2. \quad (3.3.6)$$

3.4 Estimarea parametrilor

Definiția 3.4.1. (*Estimator. Estimație*)

Se numește estimator, variabila aleatoare

$$t_n(X) : \Omega \rightarrow \Theta, \quad (3.4.1)$$

unde $X = (X_1, X_2, \dots, X_n)$, Ω este spațiul de selecție; $t_n(x), x \in S$, S spațiul observațiilor se numește estimație.

Definiția 3.4.2. (*Estimator consistent*)

Un estimator $t_n = t_n(X)$ se numește consistent pentru θ dacă

$$\lim_{n \rightarrow \infty} P(|t_n - \theta| < \epsilon) = 1 \quad (3.4.2)$$

și notăm $t_n \xrightarrow{P} \theta$.

Consistența unui estimator reprezintă o proprietate asimptotică a estimatorului. Un estimator bun pentru parametrul θ trebuie să aibă o repartiție cu o valoare centrală în vecinătatea lui θ . Definiția următoare cere ca estimatorul să aibă o valoare centrală în vecinătatea lui θ nu numai pentru valori mari ale lui n , ci pentru orice n .

Definiția 3.4.3. (*Estimator nedeplasat*)

Estimatorul t_n se numește nedeplasat pentru θ dacă

$$E[t_n] = \theta. \tag{3.4.3}$$

Bibliografie

- [Craiu (1998)] M. Craiu (1998), *Statistică matematică: teorie și probleme*, Editura Matrix Rom, București
- [Martinez, Martinez (2002)] W. L. Martinez, A. R. Martinez (2002), *Computational Statistics Handbook with MATLAB*, Chapman & Hall/CRC, Boca Raton London New York Washington, D.C.
- [Văduva (2004)] I. Văduva (2004), *Modele de simulare: note de curs*, Editura Universității din București, București