

Universitatea din București  
Facultatea de Matematică și Informatică

# METODE MODERNE DE CALCUL ȘI SIMULARE

Cursuri nr. 5-6 – Anul III – Tehnologia Informației

*Asist. dr. Bianca Mogoș*

București, Februarie 2014

# Cuprins

<b>1</b>	<b>Generarea variabilelor aleatoare</b>	<b>2</b>
1.1	Metode generale pentru generarea variabilelor aleatoare . . . . .	2
1.1.1	Numere aleatoare continue . . . . .	2
1.1.2	Funcții de o variabilă aleatoare . . . . .	3
1.1.3	Metoda inversă . . . . .	5
1.1.4	Metoda compunerii sau amestecării . . . . .	8
	<b>Bibliografie</b>	<b>12</b>

# Capitolul 1

## Generarea variabilelor aleatoare

### 1.1 Metode generale pentru generarea variabilelor aleatoare

#### 1.1.1 Numere aleatoare continue

Majoritatea metodelor de generare a v.a. se bazează pe generarea unor numere aleatoare uniform distribuite pe intervalul  $(0,1)$ . Notăm un număr aleator uniform distribuit cu  $U \sim \mathcal{U}(0,1)$ . Datorită calculatorului avem posibilitatea de a genera foarte ușor numere aleatoare uniforme. Totuși, trebuie cunoscut faptul că numerele generate de calculator sunt pseudo-aleatoare, deoarece acestea sunt generate cu un algoritm determinist.

##### Observație 1.1.1.

- În Matlab există funcția **rand** pentru generarea variabilelor aleatoare uniforme.
- **rand**( $n$ ), unde  $n$  este un număr natural, returnează o matrice de dimensiune  $n \times n$  având ca elemente numere aleatoare uniform distribuite între 0 și 1.
- **rand**( $m, n$ ), unde  $m, n$  sunt numere naturale, returnează o matrice de dimensiune  $m \times n$  având ca elemente numere aleatoare uniform distribuite între 0 și 1.
- O secvență de numere aleatoare generată în Matlab depinde de “sămânța” sau starea generatorului. Starea este resetată la valoarea implicită în momentul pornirii Matlab-ului, astfel aceeași secvență de variabile aleatoare este generată la o nouă pornire a Matlab-ului. Acesta poate fi un avantaj în situațiile în care analistul are nevoie să reproducă rezultatele unei simulări pentru a verifica anumite concluzii.

- Folosind sintaxa **rand('state',0)** Matlab-ul resetează generatorul la starea inițială.
- Se folosește sintaxa **rand('state',j)** pentru a seta generatorul la starea  $j$ .
- Pentru a obține vectorul de stări se apelează **S = rand('state')**, S va reprezenta vectorul conținând cele 35 de stări posibile.

Pentru a genera numere aleatoare uniform distribuite pe un interval  $(a,b)$ , și scriem  $X \sim \mathcal{U}(a, b)$ , pornind de la un număr generat uniform pe intervalul  $(0,1)$  se poate folosi transformarea

$$X = (b - a) \cdot U + a, \quad (1.1.1)$$

unde  $U \sim \mathcal{U}(0, 1)$

### Exemplul 1.1.2.

În acest exemplu se va ilustra utilizarea funcției **rand**.

```
% Generam un vector de numere aleatoare pe intervalul (0,1).
x = rand(1,1000);
% Histograma eșantionului generat în x.
[N,X] = hist(x,15);
% x: mulțimea eșantion
% 15 reprezintă numărul de dreptunghiuri ale histogramei
% N: vector conținând numărul de elemente din fiecare dintre dreptunghiuri.
% X: vector conținând centrele dreptunghiurilor
% Folosirea funcției bar pentru reprezentarea grafică a histogramei.
bar(X,N,1,'w')
title('Histograma asociata unei variabile aleatoare uniforme')
xlabel('X')
ylabel('Frecventa absoluta')
```

Histograma rezultată este prezentată în Figura 1.1.

### 1.1.2 Funcții de o variabilă aleatoare

Fie  $X$  o v.a.  $X : \Omega \rightarrow \mathbb{R}$  care ia valori în  $D \subset \mathbb{R}$  și  $\phi : D \rightarrow \mathbb{R}$ ,  $\phi$  continuă. Atunci v.a.  $Y = \phi(X) : \Omega \rightarrow \phi(D) \subset \mathbb{R}$  are repartiția dată de

$$P(\{\omega \in \Omega | Y(\omega) \in A\}) = P(\{\omega \in \Omega | X(\omega) \in \phi^{-1}(A)\}) \quad (1.1.2)$$

pentru orice  $A \subset \phi(D)$  și  $\phi^{-1}(A) = \{z | \phi(z) \in A\}$ .

### Proprietăți 1.1.3.

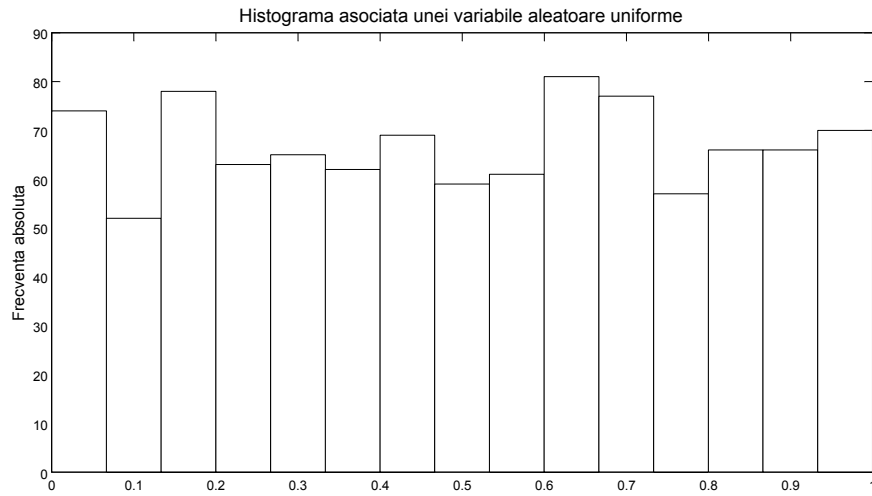


Figura 1.1: Histograma asociată unui eșantion de numere aleatoare uniform distribuite

Dacă  $X \sim N(m, \sigma^2)$  atunci  $Y = e^X$  are densitatea de repartiție:

$$f_Y(y) = \frac{1}{y\sigma\sqrt{2\pi}} e^{-\frac{(\ln y - m)^2}{2\sigma^2}}, y > 0 \quad (1.1.3)$$

Demonstrație

$$\begin{aligned} F_Y(y) &= P(\{\omega \in \Omega | Y(\omega) \leq y\}) = P(e^X \leq y) = P(X \leq \ln y) = F_X(\ln y) = \\ &= \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^{\ln y} e^{-\frac{(t-m)^2}{2\sigma^2}} dt. \end{aligned}$$

**Definiția 1.1.4.** (*Variabilă aleatoare lognormală*)

Variabila aleatoare  $Y$  având densitatea de probabilitate (1.1.3) se numește lognormală.

**Proprietăți 1.1.5.**

Dacă  $X \sim U(0, 1)$  atunci variabila aleatoare

$$Y = \left( -\frac{1}{a} \ln(1 - X) \right)^{1/b}$$

cu  $a, b > 0$  are densitatea de probabilitate

$$f(y) = aby^{b-1}e^{-ay^b}, \quad 0 < y < \infty.$$

**Definiția 1.1.6.** (*Variabilă aleatoare Weibull*)

O variabilă aleatoare cu densitatea de probabilitate (1.1.5) se numește Weibull cu parametrii  $a$  și  $b$  și este notată  $W(a, b)$ .

**Proprietăți 1.1.7.**

Fie  $X$  o variabilă aleatoare cu funcția de repartiție inversabilă  $F(X)$  de tip continuu care este strict crescătoare. Atunci variabila aleatoare  $Y = F(X)$  este repartizată uniform pe  $(0, 1)$ .

Demonstrație

Funcția de repartiție a variabilei  $Y$  este

$$P(Y \leq y) = P(F(X) \leq y) = P(X \leq F^{-1}(y), 0 < y < 1) = F(F^{-1}(y)) = y,$$

$y \in (0, 1)$ , ceea ce arată că  $Y \sim U(0, 1)$ .

Un rezultat pentru reciproca propoziției (1.1.7) este dat în următoarea propoziție.

**Teorema 1.1.8.** (*Teorema lui Hincin*)

Fie  $Y \sim U(0, 1)$  și  $F(x)$  o funcție de repartiție inversabilă, de tip continuu cu  $F(a) = 0$  și  $F(b) = 1$  și  $F$  strict crescătoare pe  $(a, b)$ . Atunci v.a.

$$X = F^{-1}(Y) \tag{1.1.4}$$

este o v.a. continuă cu funcția de repartiție  $F$ .

Demonstrație

Funcția de repartiție a v.a.  $X$  este

$$P(X \leq x) = P(F^{-1}(Y) \leq x) = P(Y \leq F(x))$$

deoarece  $F$  este strict crescătoare.

Cum  $Y \sim U(0, 1)$  rezultă  $F_Y(y) = y$  pentru  $y \in (0, 1)$ . Obținem astfel

$$P(X \leq x) = F(x).$$

### 1.1.3 Metoda inversă

Această metodă este introdusă ca o consecință directă a teoremei 1.1.8 (Teorema lui Hincin). Ea se aplică în cazul în care funcția de repartiție se poate inversa ușor. Astfel, dacă am putea produce valorile de selecție  $u_1, u_2, \dots, u_n$  asupra v.a.  $U \sim \mathcal{U}(0, 1)$  și am cunoaște funcția de repartiție  $F$  a variabilei  $X$  atunci am putea produce valorile de selecție  $x_1, x_2, \dots, x_n$  asupra lui  $X$  cu formula  $x_i = F^{-1}(u_i)$ ,  $1 \leq$

Algoritm 1.1: Metoda inversă pentru variabile aleatoare continue

Intrare	$F$ : funcția de repartiție a variabilei $X$ pe care ne propunem să o simulăm
Pas 1	Se generează o valoare de selecție $u$ uniformă pe $(0,1)$ .
Pas 2	Se determină expresia inversei funcției de repartiție $F^{-1}(u)$ .
Pas 3	Se obține valoarea de selecție dorită $x = F^{-1}(u)$ .
Ieșire	Valoarea de selecție, $x$ , a v.a. $X$

$i \leq n$ . Dacă funcția  $F^{-1}$  se poate calcula atunci valorile de selecție  $x_i$  pot fi generate folosind Algoritmul 1.1.

Spunem că acest algoritm simulează o selecție de volum  $n$  asupra v.a.  $X$ . Presupunem că putem genera valori de selecție  $u_i, 1 \leq i \leq n$  uniforme pe  $(0,1)$  și independente atunci și valorile de selecție  $x_i = F^{-1}(u_i), 1 \leq i \leq n$  sunt independente. De aceea, este suficient să dăm algoritmul pentru simularea unei singure valori de selecție, urmând să repetăm Pașii 1–3 de  $n$  ori.

În Tabelul 1.1 se prezintă câteva repartiții de probabilitate care se pot simula ușor folosind metoda inversă. În formulele lui  $f$  din tabel se precizează numai valorile lui  $x$  pentru care  $f(x) > 0$ , presupunându-se că  $f(x) = 0$  în rest.

Tabel 1.1: Variabile aleatoare care pot fi simulate folosind metoda inversă

Repartiția	Densitatea $f$	Inversa $F^{-1}$
$Exp(\lambda), \lambda > 0$	$f(x) = \lambda e^{-\lambda x}, x > 0$	$x = -\frac{1}{\lambda} \ln(u)$
$Weib(0, 1, \nu), \nu > 0$	$f(x) = \nu x^{\nu-1} e^{-x^\nu}$	$x = (-\ln(u))^{1/\nu}$
$Cauchy$	$f(x) = \frac{1}{\pi} \frac{1}{1+x^2}, x \in \mathbb{R}$	$x = \tan \pi(u - 1/2)$
$Arcsin$	$f(x) = \frac{1}{\pi} \frac{1}{\sqrt{1-x^2}}, x \in [-1, 1]$	$x = \sin \pi(u - 1/2)$

Metoda inversă se poate adapta pentru a dezvolta un algoritm pentru simularea

unei variabile discrete definite prin repartiția

$$X : \begin{pmatrix} x_1 & x_2 & \dots & x_m \\ p_1 & p_2 & \dots & p_m \end{pmatrix}, \sum_{i=1}^m p_i = 1, x_1 < x_2 < \dots < x_m. \quad (1.1.5)$$

Funcția de repartiție a variabilei  $X$  este dată de

$$F(x) = \begin{cases} 0 & \text{dacă } x < x_1 \\ p_1 & \text{dacă } x_1 \leq x < x_2 \\ p_1 + p_2 & \text{dacă } x_2 \leq x < x_3 \\ \dots & \dots \\ p_1 + p_2 + \dots + p_k & \text{dacă } x_k \leq x < x_{k+1} \\ \dots & \dots \\ 1 & \text{dacă } x \geq x_m \end{cases} \quad (1.1.6)$$

Se obține o valoare de selecție a v.a. discrete  $X$  generând un număr aleator uniform  $U$  și alegând numărul aleator  $X$  conform regulii

$$X = x_i \quad \text{dacă } F(x_{i-1}) < U \leq F(x_i). \quad (1.1.7)$$

### Exemplul 1.1.9.

Vrem să generăm o v.a. discretă  $X$  cu repartiția

$$X : \begin{pmatrix} 0 & 1 & 2 \\ 0.3 & 0.2 & 0.5 \end{pmatrix} \quad (1.1.8)$$

Funcția de repartiție este dată de

$$F(x) = \begin{cases} 0 & \text{dacă } x < 0 \\ 0.3 & \text{dacă } 0 \leq x < 1 \\ 0.5 & \text{dacă } 1 \leq x < 2 \\ 1 & \text{dacă } x \geq 2 \end{cases} \quad (1.1.9)$$

Se generează valori de selecție asupra v.a.  $X$  conform regulilor

$$X = \begin{cases} 0 & U \leq 0.3 \\ 1 & 0.3 < U \leq 0.5 \\ 2 & 0.5 < U \leq 1 \end{cases} \quad (1.1.10)$$

De exemplu, dacă variabila aleatoare uniformă  $U = 0.78$  atunci obținem valoare de selecție  $x = 2$ .



Algoritm 1.2: Metoda inversă pentru variabile aleatoare discrete

Intrare	Repartiția variabilei $X$ pe care ne propunem să o simulăm $P(X = x_i) = p_i, \sum_{i=1}^m p_i = 1, x_1 < x_2 < \dots < x_m.$
Pas 1	Se generează o valoare de selecție $U$ uniformă pe $(0,1)$ .
Pas 2	Dacă $U \leq p_1$ atunci $X = x_1$
Pas 3	Altfel dacă $U \leq p_1 + p_2$ atunci $X = x_2$
Pas 4	Altfel dacă $U \leq p_1 + p_2 + p_3$ atunci $X = x_3$
Pas 5	$\dots$ Altfel dacă $U \leq p_1 + p_2 + \dots + p_m$ atunci $X = x_m$
Ieșire	Valoarea de selecție, $X$ , a v.a. $X$

#### 1.1.4 Metoda compunerii sau amestecării

Această metodă se aplică variabilelor aleatoare  $X$  a căror repartiție de probabilitate satisface următoarea definiție.

**Definiția 1.1.10.** (*Amestecare discretă și amestecare continuă*)

Funcția de repartiție  $F(x)$  este o amestecare (compunere sau mixtură) discretă a mulțimii de funcții de repartiție  $\{F_i(x)\}_{1 \leq i \leq m}$  cu repartiția discretă

$$J : \begin{pmatrix} 1 & 2 & \dots & m \\ p_1 & p_2 & \dots & p_m \end{pmatrix}, \sum_{i=1}^m p_i = 1, \quad (1.1.11)$$

dacă

$$F(x) = \sum_{i=1}^m p_i F_i(x). \quad (1.1.12)$$

Funcția de repartiție  $F(x)$  este o amestecare continuă a familiei de funcții de repartiție  $\{G(x, Y)\}_{Y \in \mathbb{R}}$ , cu funcția de repartiție continuă  $H(y)$  a lui  $Y$  dacă este de forma

$$F(x) = \int_{\mathbb{R}} G(x, y) dH(y). \quad (1.1.13)$$

**Observație 1.1.11.**

În definiția amestecării se pot considera în loc de funcții de repartiție, densități de probabilitate și formulele devin

$$f(x) = \sum_{i=1}^m p_i f_i(x) \quad (1.1.14)$$

și respectiv

$$f(x) = \int_{\mathbb{R}} g(x, y) h(y) dy. \quad (1.1.15)$$

Pentru cazul amestecării discrete notăm cu  $X_i, i = 1, \dots, m$  v.a. având funcțiile de repartiție  $F_i(x), i = 1, \dots, m$  și definim v.a.

$$X : \begin{pmatrix} X_1 & X_2 & \dots & X_m \\ p_1 & p_2 & \dots & p_m \end{pmatrix}, \quad (1.1.16)$$

cu proprietățile:

$$X_i \cap X_j = \emptyset, \forall i \neq j, \bigcup_i \{X = X_i\} = \Omega \quad (1.1.17)$$

și

$$X_i(\{X_i \neq X\}) \subset A_i, A_i \cap X_i(\{X_i = X\}) = \emptyset \text{ cu } P(X_i^{-1}(A_i)) = 0. \quad (1.1.18)$$

Arătăm că v.a.  $X$ , definită în (1.1.16), are funcția de repartiție  $F(x) = \sum_{i=1}^m p_i F_i(x)$ .

Calculăm  $P(X \leq x)$  precum urmează:

$$\begin{aligned} P(\{X \leq x\}) &= P(\{X \leq x\} \cap (\{X = X_1\} \cup \dots \cup \{X = X_m\})) \\ &= P\left(\bigcup_{i=1}^m (\{X \leq x\} \cap \{X = X_i\})\right) \\ &= \sum_{i=1}^m P(\{X \leq x\} \cap \{X = X_i\}) \\ &= \sum_{i=1}^m P(\{X_i \leq x\}) \cdot P(\{X = X_i\}) \\ &= \sum_{i=1}^m p_i F_i(x). \end{aligned} \quad (1.1.19)$$

Am folosit faptul că

$$\{\{X \leq x\} \cap \{X = X_i\}\} \cap \{\{X \leq x\} \cap \{X = X_j\}\} = \emptyset, \forall i \neq j$$

și că evenimentele

$$\{X_i \leq x\} \text{ și } \{X = X_i\}$$

sunt independente.

Procedura de generare a unei valori de selecție a v.a.  $X$  este prezentată în Algoritm 1.3.

Algoritm 1.3: Metoda amestecării discrete

Intrare	<p>Funcțiile de repartiție <math>F_i(x)</math> ale v.a. <math>X_i</math></p> <p>Repartiția v.a. discrete <math>J</math>: <math>P(X = i) = p_i, \sum_{i=1}^m p_i = 1</math></p>
Pas 1	Se generează un indice $j$ având repartiția $J$
Pas 2	Se generează $X_j$ cu funcția de repartiție $F_j(x)$
Pas 3	Se definește $X = X_j$
Ieșire	Valoarea de selecție, $X$ , a v.a. $X$

### Exemplul 1.1.12.

Fie  $X$  variabila având repartiția Laplace a cărei densitate de probabilitate este

$$f(x) = \frac{\lambda}{2} e^{-\lambda|x|}, x \in \mathbb{R}, \lambda > 0 \quad (1.1.20)$$

Observăm că

$$f(x) = p_1 f_1(x) + p_2 f_2(x), p_1 = p_2 = \frac{1}{2}$$

unde

$$f_1(x) = \begin{cases} \lambda e^{\lambda x} & \text{dacă } x \leq 0 \\ 0 & \text{dacă } x > 0 \end{cases}, f_2(x) = \begin{cases} 0 & \text{dacă } x \leq 0 \\ \lambda e^{-\lambda x} & \text{dacă } x > 0 \end{cases}.$$

Generarea variabilei  $X$  este realizată folosind Algoritm 1.4.

Algoritm 1.4: Metoda amestecării discrete

Intrare	V.a. $Y \sim \text{Exp}(\lambda)$ cu densitatea de probabilitate $f_2(x)$ și V.a. $-Y$ cu densitatea de probabilitate $f_1(x)$
Pas 1	Se generează $U \sim \mathcal{U}(0, 1)$
Pas 2	Dacă $U \leq 0.5$ atunci mergi la Pas 3; altfel mergi la Pas 4
Pas 3	$s = 1$ ; mergi la Pas 5
Pas 4	$s = -1$
Pas 5	Se generează $Y \sim \text{Exp}(\lambda)$
Pas 6	Se definește $X = sY$
Ieșire	Valoarea de selecție, $X$ , a v.a. $X$ .

# Bibliografie

- [Craiu (1998)] M. Craiu (1998), *Statistică matematică: teorie și probleme*, Editura Matrix Rom, București
- [Martinez, Martinez (2002)] W. L. Martinez, A. R. Martinez (2002), *Computational Statistics Handbook with MATLAB*, Chapman & Hall/CRC, Boca Raton London New York Washington, D.C.
- [Văduva (2004)] I. Văduva (2004), *Modele de simulare: note de curs*, Editura Universității din București, București